

에이전트 기반 국방 무기체계 정비지원 RAG 시스템 구성 방안 연구

A Study on the Configuration of a Agent-Based RAG System for Maintenance Support of Defense Weapon Systems

김 건 희¹ 추 건 호¹ 노 웅 석² 최 종 천^{1*}
Geon-Hee Kim Keon-Ho Chu Woong-Seok Roh Jong-Cheon Choi

요 약

국방 무기체계 유지보수 현장에는 방대한 정비 교범과 지침이 문서 및 전자교범 형태로 축적되어 있다. 이를 효과적으로 활용하기 위한 키워드 기반 검색 방식은 정비사가 필요한 정보와 절차를 신속·정확하게 탐색하는 데 한계가 있어 정비 시간 지연과 인적 오류를 초래한다. 이에 본 연구는 최근 주목받는 생성형 인공지능 기반 RAG(Retrieval-Augmented Generation) 기술과 LLM 에이전트 아키텍처를 활용하여, 국방 무기체계 정비 교범에 대한 도메인 지식을 갖춘 정비 지원 챗봇 시스템의 구성 방안을 제안한다. 제안 시스템은 정비 문서 전처리, 의미 기반 검색을 위한 벡터 데이터베이스, 사용자의 자연어 질의를 해석하여 관련 문서를 검색·요약하는 에이전트 모듈로 구성되며, 정비사로부터 장비 결함 및 부품 정보를 입력받아 문맥에 부합하는 정비 절차와 관련 이미지를 통합 제공한다. 이를 통해 보다 편리하고 빠르며 정확한 정비를 지원함으로써 정비 시간 단축과 정비 오류 감소를 도모하고, 궁극적으로 국방 무기체계의 가동률 향상과 전투준비태세 유지에 이바지할 수 있을 것으로 기대한다.

☞ 주제어 : 검색 증강 생성, 국방 무기체계, 정비 지원, AI 챗봇, 기술 교범, 대규모 언어 모델, 국방 정비지원 에이전트

ABSTRACT

In the maintenance field of defense weapon systems, vast volumes of maintenance manuals and technical guidelines have been accumulated in both printed and electronic formats. However, conventional keyword-based search methods have limitations in enabling maintenance personnel to quickly and accurately locate the necessary information and procedures, resulting in delays in maintenance time and increased risk of human error. To address this issue, this study proposes the design of a maintenance support chatbot system equipped with domain knowledge of defense weapon system maintenance manuals, leveraging RAG (Retrieval-Augmented Generation) technology based on generative artificial intelligence and an LLM agent architecture. The proposed system consists of document preprocessing for maintenance manuals, a vector database for semantic-based retrieval, and an agent module that interprets users' natural language queries to retrieve and summarize relevant documents. By receiving equipment fault descriptions and component information from maintenance personnel, the system provides contextually appropriate maintenance procedures along with related images. Through this approach, the system aims to support more convenient, faster, and more accurate maintenance operations, thereby reducing maintenance time and errors. Ultimately, it is expected to enhance the operational availability of defense weapon systems and contribute to maintaining combat readiness.

☞ keyword : Retrieval-Augmented Generation (RAG), Defense Weapon System, Maintenance Support, AI Chatbot, Technical Manual, Large Language Model (LLM), Defense maintenance support Agent

1. 서 론

현재 국방 무기체계의 가동률(Operational Availability)

과 상시 전투 준비 태세(Combat Readiness) 유지는 국가 방위력의 근간이며, 이는 신속하고 정확한 유지보수 능력에 직결된다. 정비 현장에는 방대한 기술 교범(Manuals)과 지침서가 존재하지만, 이 정보들이 여러 매뉴얼에 산재해 있어 정비사들은 필요한 정보를 정확히 탐색하고 해석하는 데 상당한 시간을 소모하는 고질적인 문제를 안고 있다 [1].

최근에는 교범을 전자교범 형태로 변환하여 키워드 검색

¹ AI Tech Research Lab, LIG System, Seoul, 04418, Korea

² CSISR IPS Lab, LIG D&A, Seongnam-si, 13488, Korea

* Corresponding author (jongcheon.choi@lig.kr)

[Received 14 November 2025, Reviewed 19 November 2025(R2 17 March 2026), Accepted 30 March 2026]

색을 통한 정보검색을 제공하지만, 정보 탐색의 근본적인 한계는 여전히 존재한다. 예를 들어 자이로센서 X축 고장이 발생할 경우 “자이로센서”라는 키워드로 검색하게 되면, 자이로센서라는 단어가 포함된 방대한 결과가 제공되며, 정비사는 이 중 X축 고장에 관련된 내용을 직접 선별해야 하는 번거로움이 있다. 이러한 정보 접근성의 한계는 단순히 정비 시간을 지연시키는 것을 넘어, 유사한 부품이나 절차를 잘못 선택하는 휴먼 에러(Human Error)와 오래된 버전의 교범 참조로 인한 정비 오류(Maintenance Error)의 잠재적 위험을 증가시키는 요인이 될 수 있다 [2].

최근 대규모 언어 모델(Large Language Model, LLM)이 뛰어난 자연어 이해 및 생성 능력으로 다양한 분야에서 주목받고 있다 [3]. 하지만 LLM은 사전 학습된 데이터를 기반으로, 확률적으로 답변을 생성하는 과정에서, 사실과 부합하지 않는 정보를 그럴듯하게 생성하는 환각(Hallucination) 현상을 본질적인 한계로 안고 있다 [4,5]. 무기체계 정비와 같이 단 하나의 오류도 치명적인 장비 손상이나 인명 사고로 직결될 수 있는 고신뢰성(High-reliability) 도메인에서, 환각에 기반한 잘못된 정비 정보 제공은 매우 위험하다. 이러한 LLM의 한계를 보완하고 도메인 특화 지식의 정확성을 보장하기 위한 기술로 “검색 증강 생성(Retrieval-Augmented Generation, RAG)”이 강력한 대안으로 부상하고 있다 [6]. RAG는 LLM이 답변을 생성할 때, 신뢰할 수 있는 외부 지식 소스(본 연구의 경우, ‘기술 교범 데이터베이스’)에서 관련 정보를 실시간으로 검색하고, 이 명확한 근거를 바탕으로 답변을 생성하도록 유도한다 [7]. 이는 LLM의 환각 현상을 획기적으로 억제하고, 정보의 출처를 명확히 하여 답변의 신뢰성을 극대화할 수 있는 접근법이다.

본 연구의 목적은 이러한 RAG 기술을 핵심 기반으로 활용하여, 국방 무기체계 정비 현장의 특수성을 반영한 지능형 정비지원 AI 챗봇 시스템의 구체적인 구성 방안을 제안하는 데 있다. 본 연구에서 제안하는 시스템은 단순한 텍스트 질의응답을 넘어, 정비 절차(텍스트)와 관련 부품 이미지 및 도면(시각 자료)을 유기적으로 결합하여 제공하는 것을 목표로 한다. 이를 위해, LLM을 단순 생성기가 아닌 에이전트(Agent)로 활용하여, 정비 품목 및 버전별로 관리되는 기술 교범(Vector DB)과 부품 및 정비 이미지 정보(RDB)를 선택적으로 조회하고, 최신 교범 버전에 기반한 통합된 답변을 생성하는 아키텍처를 제시한다. 이러한 지식베이스 설계를 통해 구버전 교범 참조나 유사 부품 오인식으로 인한 잘못된 정비 절차 수행 위험을 구조적으로 완화하고자 한다. 정비 효율성에 대해서는,

본 논문에서 직접 운용 데이터를 계측하기보다는 정비 절차 및 이미지 제공 정확도 향상을 통해 그 가능성을 탐색하는 것을 목표로 한다. 본 연구를 통해 제안되는 시스템은 국방 무기체계 정비의 효율성과 정확성을 극대화하여, 궁극적으로 무기체계 가동률 향상과 전투 준비 태세 유지에 기여하고자 한다.

2. 관련 연구


2.1 대규모 언어 모델(Large Language Model, LLM)

대규모 언어 모델(LLM)은 수백억 개 이상의 방대한 파라미터를 가진 심층 학습 모델로, 트랜스포머(Transformer) 아키텍처를 기반으로 한다. 2017년 제안된 오리지널 트랜스포머는 입력을 이해하는 인코더(Encoder)와 출력을 생성하는 디코더(Decoder)가 결합한 구조였으나, 최근 GPT(Generative Pre-trained Transformer) 계열 및 Gemini와 같은 최신 생성형 AI 모델들은 대부분 디코더 전용(Decoder-only) 아키텍처를 채택하고 있다 [8].

디코더 전용 구조는 자기 회귀(Autoregressive) 방식을 통해 작동하며, 주어진 문맥을 바탕으로 다음에 올 단어를 순차적으로 예측하여 텍스트를 생성(Generation)하는 작업에 고도로 특화되어 있다. LLM은 텍스트 요약, 번역, 질의응답 등 광범위한 자연어 처리(NLP) 작업에서 인간과 유사한 성능을 보여주며 AI 챗봇의 핵심 엔진으로 자리 잡았다. 하지만 LLM은 학습 데이터에 존재하지 않는 최신 정보에 취약하며, 확률적 생성 과정에서 사전 학습된 지식에만 의존하여 사실과 부합하지 않는 내용을 그럴듯하게 생성하는 환각(Hallucination) 현상을 본질적인 한계로 가진다 [9].

2.2 검색 증강 생성(Retrieval-Augmented Generation, RAG)

검색 증강 생성(RAG)은 LLM의 환각 현상을 완화하고, 도메인 특화된 최신 지식을 제공하기 위해 고안된 핵심적인 LLM 구축 기술이다 [10,11]. RAG는 LLM이 답변을 생성하기 전에 외부의 신뢰할 수 있는 지식 소스를 실시간으로 검색(Retrieve)하고, 검색된 문맥(Context)을 입력 프롬프트에 함께 주입하여 LLM이 이 문맥에 기반해 답변을 생성하도록 유도하는 아키텍처이다. RAG의 일반적인 아키텍처는 그림 1과 같다.



(그림 1) RAG의 구조
(Figure 1) RAG Architecture

2.2.1 데이터 인덱싱(Indexing)

기술 교범과 같은 원본 문서를 의미론적 단위(Chunk)로 나눈 뒤, 각 조각을 임베딩 모델을 통해 벡터로 변환하여 벡터 데이터베이스(Vector Database)에 저장한다. 벡터 데이터베이스 솔루션에는 표 1과 같이 고성능 검색 라이브러리인 FAISS, 완전 관리형 상용 서비스인 Pinecone, 그리고 본 연구에서 채택한 Chroma DB와 같은 다양한 도구가 존재한다.

(표 1) 벡터 데이터베이스 솔루션 비교
(Table 1) Comparison of Vector Database Solutions

벡터DB	유형	비고	LangChain 통합	주요 사용 사례
chromaDB	오픈소스, 임베딩 DB	경량성/병도 서버 설정 불필요 개발원인상 Python/JavaScript, LangChain과 통합이 매우 용이 빠른 프로토타이핑에 최적화	매우 높음 (기본 지원)	개방 프로토타이핑 소/중 규모 애플리케이션
FAISS	오픈소스/벡터 검색 라이브러리	검색속도/GPU 가속 지원, 빠른 검색 속도 효율성: 메모리 최적화 기능 제공 (단, DB가 아닌 라이브러리이므로 별도 DB 기능 필요)	높음 (VectorStore로 지원)	고성능 검색엔진, 학술 연구, 대용량 인덱싱
Pinecone	상용 완전 관리형 (SaaS)	관리 용이성/서버 관리/운영 불필요(SaaS) 확장성/대규모 트래픽 및 데이터에 용이 안정적인 프로덕션 환경 제공	매우 높음 (기본 지원)	대규모 상용 서비스, 프로덕션 환경

2.2.2 검색(Retrieval)

사용자의 질의(Query)가 입력되면, 해당 질의를 벡터로 변환한다. 이 질의 벡터와 벡터 DB 내의 문서 벡터 간의 의미 기반 검색(Semantic Search)을 수행하여, 질의와 가장 관련성이 높은 상위 K개의 문맥 조각을 추출한다 [12].

2.2.3 생성(Generation)

추출된 문맥들과 사용자의 원본 질의가 LLM의 입력 프롬프트로 함께 전달된다. LLM은 이 정보에 기반하여 질의에 대한 답변을 생성한다 [13].

이처럼 RAG는 검색을 통해 수집된 정보를 활용하여 LLM이 부정확한 정보를 생성하는 것을 방지하고, 답변의 근거를 명확히 제시할 수 있게 한다 [14]. 또한, 파인튜닝(Fine-tuning) 대비 비교적 적은 비용으로 지식 소스를 지속해서 업데이트할 수 있다는 장점이 있다.

2.3 에이전트(Agent) 및 도구(Tool)

단순한 RAG가 '질의→검색→답변'의 1단계 프로세스를 따른다면, LLM 에이전트(Agent)는 한 단계 확장된 개념으로, LLM을 추론과 의사결정을 수행하는 중심 모듈로 활용하는 고급 아키텍처를 의미한다 [15]. 에이전트는 복잡한 문제 해결을 위해 스스로 계획(Planning)을 수립하고, 기억(Memory)을 통해 맥락을 유지하며, 외부 환경과의 상호작용을 통해 행동(Action)을 실행한다. 이러한 구조의 핵심은 도구(Tool) 사용이다.

에이전트는 주어진 목표를 달성하기 위해 자신이 접근할 수 있는 도구의 목록을 인식하고 있으며, 각 도구는 특정 기능을 수행하는 함수(Function) 형태로 정의된다. 예를 들어, 벡터 데이터베이스 내에서 사용자의 질의와 유사한 정보를 검색하는 정보검색기, 웹 검색기, 계산기, 데이터베이스 조회기 등이 대표적이며, LLM 에이전트의 작동 방식은 다음과 같다.

2.3.1 추론(Reasoning)

에이전트는 사용자의 복합적인 질의(예: “A 부품의 재고를 확인하고, B 교범에서 관련 절차를 찾아줘”)를 분석하여 문제 해결을 위한 하위 과제를 식별한다.

2.3.2 도구 선택(Tool Selection)

질의 해결에 필요한 기능을 판단하고, 예를 들어 관계형 데이터베이스 조회 도구(재고 확인용)와 벡터 데이터베이스 검색 도구(교범 검색용)를 선택한다.

2.3.3 반복 실행(Iteration)

에이전트는 계획에 따라 각 도구를 순차적 또는 병렬적으로 호출하고, 그 결과를 다시 입력으로 받아 추론 - 행동 루프를 반복하며 최종 응답을 생성한다.

본 연구에서 제안하는 정비 절차(Vector DB)와 부품 이미지(RDB)의 동시 제공 구조는, 이러한 LLM 에이전트가 두 개의 이질적인 도구를 자율적으로 선택하고 결합

하는 복합적 추론 과정을 통해서 구현할 수 있다.

3. 에이전트 기반 RAG 시스템 및 지식 데이터베이스 구성 방안


3.1 기존 연구 고찰 및 본 연구의 차별성

RAG 및 LLM을 활용한 지능형 챗봇 시스템은 산업 및 국방 분야에서 활발히 연구·도입되고 있다. 최근 한국 육군은 온프레미스(On-premise) LLM과 RAG 기술을 도입하여 국방부 훈령, 규정, 군사 용어사전 등을 효과적으로 검색·활용하는 ‘육군 지능형 스마트 부대 시범체계 구축 사업’을 추진한 바 있다 [16]. 이러한 기존 시스템들은 대부분 텍스트 위주의 문서 검색·요약 기능에 초점을 맞추고 있어, 정비 교범에 포함된 이미지, 도면, 구성도와 같은 시각 자료를 정비 절차와 함께 연계·제공하지 못하거나, 텍스트와 이미지를 별도의 시스템에서 따로 조회해야 하는 한계를 가진다. 그 결과, 정비사는 텍스트로 절차를 확인한 뒤 별도로 교범의 도면 페이지를 찾아보아야 하고, 유사한 부품·장비를 혼동할 가능성이 남아 있어 정비 시간 증가와 인적 오류(human error), 즉 작업자의 판단 착오나 정보 확인 과정에서 발생하는 실수로 인한 작업 오류의 위험이 상존한다 [17,18,19].

본 연구는 이러한 한계를 보완하기 위해 LLM 에이전트 아키텍처를 도입하여 두 가지 이질적인 데이터 소스를 유기적으로 결합하는 구성 방안을 제안한다는 점에서 명확한 차별성을 가진다. 구체적으로, 정비사가 질의를 입력하면 LLM 에이전트는 질의를 분석하여 부품 코드, 모델명, 장비 유형 등 핵심 엔티티(Entity)를 추출하고, 이를 바탕으로 벡터 데이터베이스에서 관련 정비 절차 텍스트를 의미 기반으로 검색하는 동시에, 관계형 데이터베이스에서 해당 절차에 대응하는 부품 이미지 및 도면 경로를 조회한다. 이렇게 연동된 텍스트와 시각 자료를 하나의 응답으로 통합하여 제공함으로써, 정비사는 별도의 검색 없이 해당 장비·부품에 정확히 대응하는 절차와 이미지를 동시에 확인할 수 있다. 이는 텍스트 중심 RAG 시스템이 가지는 “절차는 알려주지만 실제 부품·구조를 눈으로 확인하기 어렵다”는 한계를 완화하고, 유사 부품 혼동과 같은 인적 오류를 줄이면서 정비 과업의 직관성과 정확성을 향상시키는 효율적인 접근 방식이다.

3.2 시스템 아키텍처

본 연구에서 제안하는 정비지원 RAG 시스템의 전체 아키텍처는 그림 2과 같다. 시스템은 LangChain 프레임워크를 기반으로 설계되었으며, LLM 에이전트(Agent)를 중앙 컨트롤러로 활용한다.



(그림 2) 에이전트 기반 정비지원 RAG 시스템 아키텍처
(Figure 2) Agent-based Maintenance Support RAG System Architecture

본 시스템은 사용자가 직관적으로 질의를 구성할 수 있도록, 대표적인 정비 상황(장비명, 증상 조합 등)에 대한 예시 질문을 함께 제시한다. 사용자가 자연어로 질의를 입력하면, LLM 에이전트는 먼저 `query_structuring` 도구를 호출하여 질의의 의도를 분석하고, 정비 목적, 대상 장비, 고장 증상, 필요한 정보 유형과 같은 핵심 엔티티 및 속성을 추출 및 정리한다. 에이전트는 이 정보를 바탕으로 `retrieve_context` 도구를 호출하여 벡터 데이터 베이스에서 관련성이 높은 상위 3개의 문맥($k=3$)을 검색한다. 검색된 정보(관련 페이지 번호, 부품 코드)를 활용하여 `get_equipment_image` 도구를 호출, 관계형 데이터베이스(MySQL)에서 해당 절차에 필요한 이미지 경로를 조회한다. 마지막으로 에이전트는 검색된 텍스트 절차와 이미지 경로를 최종 답변 생성 LLM의 입력으로 사용하여, 텍스트와 시각 자료가 결합한 통합적인 최종 답변을 생성한다.

이 아키텍처는 두 개의 이질적인 데이터베이스(Vector DB, RDB)를 에이전트가 자율적으로 연동하여, 단순 텍스트 답변을 넘어선 복합적인 정보(절차+이미지)를 제공하는 것을 특징으로 하며 에이전트는 사용자의 질문 의도를 먼저 분석하여 도구(Tool)를 활용한 RAG 답변이 필요한지(예: 정비 질의), 혹은 단순한 챗봇 응답으로 충분한지(예: 일반 대화)를 자율적으로 선택한다. 이는 모든 질의에 불필요하게 RAG를 수행하는 대신, 효율적인 RAG를 가능하게 하는 본 시스템의 핵심적인 장점이다.

3.3 지식베이스 구축 방안

정비 매뉴얼은 텍스트 절차와 시각적 이미지 데이터가 복합적으로 구성되어 있다. 이러한 데이터를 단일 데이터 베이스로 효율적으로 관리하고 검색하는 것은 제한적이다. 따라서 본 연구에서는 지식베이스를 의미 검색을 위한 벡터 DB와 검색된 정보에 해당하는 장비의 정비 이미지를 제공하기 위해 RDB를 구성하여 이중 계층 구조로 구축하였다.

3.3.1 벡터 DB 구축

본 시스템은 PDF 형태의 원본 정비 매뉴얼을 벡터 DB로 구축하기 위해 Chroma DB를 활용한다. Chroma DB는 별도의 복잡한 서버 설정 없이 신속하게 임베딩 데이터 베이스를 구축할 수 있으며 본 시스템의 기반 프레임워크인 LangChain과의 호환성 및 통합이 매우 용이하여 연구 및 프로토타이핑 단계에서 의미 기반 검색 기능을 빠르고 효율적으로 구현할 수 있다.

벡터 데이터 베이스를 구성하기 위해서 원본 정비 교범 PDF에서 정비 관련 이미지 데이터를 분리하고 텍스트 내용에 대해서 장비명, 고장 증상, 관련 페이지 등 의미 있는 단위로 재구성한다. 재구성된 문서는 Chunking과 Embedding 과정을 통해 벡터로 변환한 후 Chroma DB에 인덱싱한다. 이때 Embedding은 트랜스포머 인코더 기반 모델인 multilingual-e5-large-instruct를 사용한다.

3.3.2 정형/시각 자료 지식베이스 RDB 구축

정비 관련 이미지 데이터는 장비명, 부품 코드를 기준으로 분류하고 서버의 별도 파일 디렉터리에 저장하여 장비명 또는 부품 코드 등의 키(Key)값을 통해 경로 조회 및 이미지 로드가 가능하도록 MySQL을 사용하여 관계형 데이터베이스(RDB)로 구축하였다.

3.4 LLM 에이전트 및 도구(Tool) 설계

본 시스템의 핵심인 LLM 에이전트는 LangChain의 에이전트 프레임워크를 기반으로 구현되었다. 에이전트는 LLM을 단순 생성기가 아닌 추론하는 '뇌'로 사용하여, 주어진 3개의 도구(Tool)를 자율적으로 선택하고 호출하여 복잡한 작업을 수행한다. 에이전트에게 제공된 도구 목록은 다음과 같다.

3.4.1 query_structuring (질의 구조화 도구)

query_structuring 도구는 사용자의 자연어 질의를 입력 받는다. 질의가 일반 대화인지 정비 관련 질의인지 판단한다. 정비 질의일 경우, 문장에서 '부품명', '제품번호', '고장 증상' 등 핵심 엔티티를 추출하여 "장비명: **, 고장 증상: **"과 같은 구조화된 포맷으로 변환한다.

3.4.2 retrieve_context (문맥 검색 도구)

retrieve_context 도구는 query_structuring을 통해 구조화된 질의 또는 원본 질의를 받아, Chroma DB에서 의미상으로 가장 유사한 정비 절차 문맥 3개(k=3)를 검색하여 반환한다.

3.4.3 get_equipment_image (이미지 경로 조회 도구)

retrieve_context를 통해 검색된 텍스트(예: "관련 페이지: 125")에서 이미지 조회를 위한 장비명 또는 부품 코드 등의 키(Key)값을 식별한다. 이 키값을 사용하여 MySQL 데이터베이스를 조회하고, 조회된 이미지 파일 경로(예: /img/manual/page_125.png)를 반환한다.

3.5 에이전트 기반 정비지원 시나리오

본 시스템에서 제안하는 아키텍처와 도구를 활용하여 시스템이 동작하는 시나리오는 다음과 같다. 실제 군에서 사용하는 정비교범은 보안 문서에 해당하므로 실제 구축 사례 대신 ** 장비라는 예시로 대체한다.

1단계 (입력): 정비사가 "** 장비 음성 수신이 되나 확인기가 동작하지 않습니다. 조치 절차 알려줘" 라고, 질의한다.

2단계 (Tool 1 호출): 에이전트가 이 질의를 받고, query_structuring 도구를 호출한다. 도구는 {장비명: '** 장비', 고장증상: '확성기가 동작하지 않음'} 형태의 구조화된 데이터를 반환한다.

3단계 (Tool 2 호출): 에이전트가 이 구조화된 정보를 바탕으로 retrieve_context 도구를 호출한다. ChromaDB는 '**장비 기동 불량'과 가장 관련성이 높은 3개의 정비 절차 텍스트(Context 1, 2, 3)를 반환한다. (예: Context 1 = "다중계기를 사용하여 **시험.. [관련 페이지: 88]")

4단계 (Tool 3 호출): 에이전트는 Context 1에서 '관련 페이지: 88'이라는 키를 식별하고, get_image_path 도구를

호출한다. MySQL은 '88' 페이지에 해당하는 이미지 경로(예: /img/p88.jpg)를 반환한다.

5단계 (최종 생성): 에이전트(LLM)는 3개의 텍스트 절차와 1개의 이미지 경로를 모두 취합하여, 정비사에게 텍스트(절차)와 관련 교범 이미지(시각 자료)를 함께 포함한 최종 응답을 생성하여 제공한다.

4. 연구 결과

4.1 구성 환경

본 연구에서 제안하는 에이전트 기반 RAG 시스템은 군 실제 운용 환경 및 호환성을 고려하여 설계되었다. 시스템의 안정적인 구동과 고속 추론을 위해 운영체제(OS)는 Windows 11을 기반으로 하되, WSL2(Windows Subsystem for Linux) 환경에서 Docker(28 이상 버전) 컨테이너 기반 실행 환경을 구축하였다. LLM 모델의 서버는 vLLM(v0.10.1.1) 프레임워크에서 제공하는 공식 컨테이너 이미지를 활용하여 구성하였다.

본 연구에서는 약 20B 파라미터 규모의 GPT OSS 20B 모델을 LLM으로 사용하여 정비 질의응답을 수행하였다. 정비 교범 문서의 의미 기반 검색을 위해 BGE-M3 임베딩 모델을 사용하여 문서를 벡터화하였으며, 생성된 임베딩 벡터는 **Chroma 벡터 데이터베이스(Vector DB)**에 저장하여 검색에 활용하였다. 또한 정비 절차와 연계되는 부품 이미지 및 도면 경로 정보는 MySQL(8.0 이상) 기반 관계형 데이터베이스에서 관리하도록 구성하였다.

LLM은 PagedAttention과 같은 메모리 관리 기술을 통해 LLM 추론 속도를 향상시켜 정비 현장에서 요구되는 실시간 질의응답 환경을 지원한다. 본 연구에서는 약 20B 규모의 LLM을 실시간에 가까운 응답 시간으로 운용하기 위해 다수의 GPU 메모리와 연산 성능을 확보할 수 있는 고성능 워크스테이션 환경을 구성하였다. 실험에 사용된 하드웨어는 NVIDIA RTX A5500 GPU 2장을 기반으로 구축하였다. 특히 군부대 내 실제 운용 환경을 고려할 때 별도의 서버랙이나 데이터센터 인프라를 구축하기보다는 부대 전산실 수준에서 설치 및 운영이 가능한 워크스테이션 형태의 장비가 더욱 현실적인 배치 방식이라는 점을 반영하였다. 이러한 이유로 본 시스템에서 사용한 하드웨어 구성은 20B 급 LLM의 온프레미스 추론을 지원하면서도 실제 부대 환경에서 운용할 수 있는 수준의 고성능 하드웨어 환경으로 판단된다.

(표 2) 하드웨어 성능

(Table 2) Hardware Performance

구분	사양	비고
CPU	AMD Ryzen Threadripper PRO 5975WX 32-Cores	군 운용 환경을 고려한 워크스테이션급 하드웨어 구성
GPU	NVIDIA RTX A5500 * 2	
RAM	SSD 128GB	

4.2 성능 평가

제안하는 '에이전트 기반 RAG 시스템'은 벡터 DB와 RDB를 복합하여 지식베이스를 구축하고 AI 기반 에이전트가 지식베이스를 활용하여 답변과 이미지 등을 제공함으로써 정비지원을 제공한다. 제안한 구성의 실질적인 정비지원 성능을 검증하기 위해, 정비 교범 PDF 문서를 전처리 없이 Chunking과 Embedding만 수행하여 벡터 DB를 구축한 단순 RAG 시스템을 비교군으로 설정하여 평가를 진행하였다. 평가용 질의는 군 장교 출신 인원을 대상으로 한 인터뷰를 통해 실제 운용 부대에서 빈번히 발생하는 정비 상황을 수집하고, 해당 장비의 정비 교범 본문 및 부록에 수록된 고장 원인-증상-조치 방법 자료를 참고하여 구성하였다. 구체적으로, 전원 불량, 기동 불능, 센서 오동작, 경고등 점등 등 정비 교범 부록에서 제시하는 대표적인 고장 유형과 그에 대한 표준 조치 절차를 중심으로 질의를 설계하였으며, 이러한 시나리오를 균형 있게 포함하도록 선별한 100개의 질의-응답 쌍을 최종 데이터 세트로 사용하였다. 이 데이터 세트는 각 질의에 대해 교범 상의 표준 정답 절차와 해당 절차 수행에 필요한 정답 이미지를 함께 포함하고 있다. 따라서 본 논문에서 사용한 100개의 질의는 단일 임의 예시가 아니라, 정비 교범이 제시하는 대표 고장 시나리오를 기반으로 한 군 정비 업무상 보편적인 질의 집합으로 볼 수 있다.

평가 지표의 경우 답변 정확도와 이미지 정확도로 세분화하였으며, 100개의 질의에 대해 에이전트가 생성한 답변 및 이미지의 일치 비율의 산술평균을 사용하였다.

그림 3은 평가를 위한 질의-응답 데이터 구조이며, 정비 교범의 경우 보안 문서이므로 본 논문에는 **장비로 대체한다. 그 결과 표3과 같이 본 연구에서 제안하는 에이전트 기반 RAG 시스템이 기존 대비 약 50% 이상의 성능 개선이 있었다.

No	질문지	정답지	관련이미지
1	**장치의 전원이 인가되지 않는다	예상 원인 및 조치방법: { [*]**장치 전원 필터 결함, ****장비를 사용하여 전원 필터의 **시험을 수행한다) [*]**장치 배선장치 결함, ****장비를 사용하여 배선장치의 **시험을 수행한다) (케이블조립체 결함, ****장비를 사용하여 케이블조립체의 **시험을 수행한다) } 장비명: **장치 관련 부품명: 케이블조립체 부품번호:1578121	248.png 251.png 267.png
2	**장치 1의 스위치가 '참'에 위치시켰을 때, ** 장치1 상태램프가 점등되지 않는다.	예상 원인 및 조치방법: { [*]**기록장치 모체용 **카드조립체 결함, 모체용 **카드조립체를 교환한다) [*]**장치 배선장치 결함, ****장비를 사용하여 배선장치의 **시험을 수행한다) } 장비명: **장치 관련 부품명: **카드조립체 부품번호:8455411	347.png 359.png

(그림 3) 평가를 위한 질의-응답 데이터 구조
(Figure 3) Question - Answer Data Structure for Evaluation

(표 3) 성능 평가 결과
(Table 3) Performance Evaluation Results

모델	답변 정확도 (Text)	이미지 정확도 (Image)	비고
단순 RAG	48% (48/100)	0% (0/100)	이미지 검색 기능 부재
에이전트 기반 RAG	98% (98/100)	95% (95/100)	텍스트-이미지 동시제공

5. 결 론

본 연구는 국방 무기체계 정비 현장에서 발생하는 고질적인 정보 접근성 문제를 해결하기 위해, 지능형 정비지원 RAG(검색 증강 생성) 시스템의 구체적인 '구성 방안'을 제안하고 그 실효성을 검증하였다. 기존의 키워드 검색 시스템은 방대한 기술교범에서 정비사가 필요로 하는 문맥적 정보나 시각 자료를 신속하고 정확하게 제공하는 데 명확한 한계를 보였다.

이를 해결하기 위해, 본 연구에서는 단순 RAG 시스템을 넘어 LLM 에이전트(Agent)를 기반으로 하는 고도화된 아키텍처를 제안하였다. 제안하는 시스템의 핵심은 정비 매뉴얼의 이미지 데이터를 효과적으로 처리하기 위한 지식베이스 이중 계층 구축 방안이다. 즉, 정비 절차와 같은 비정형 텍스트는 Vector DB(Chroma DB)에, 부품 이미지 경로와 같은 데이터는 RDB(MySQL)에 분리하여 구축하였다. LLM 에이전트는 query_structuring, retrieve_context, get_image_path와 같은 3개의 도구(Tool)를 자율적으로 활용하여, 이 두 이질적인 데이터베이스를 실시간으로 연동하고 텍스트(절차)와 이미지(시각 자료)가 통합된 복합적

인 응답을 생성한다.

제안 시스템의 성능을 검증하기 위해, 20B 급 경량 LLM(gpt-oss)과 RTX A5500 GPU 환경에서 100건의 정비질의 테스트 세트를 구축하여 평가를 수행하였다. 원본 데이터를 그대로 활용한 비교군은 낮은 텍스트 정확도를 보였으며 이미지 연동은 불가능하였다. 반면, 본 연구에서 제안한 에이전트 기반 시스템은 높은 정확도로 정확한 정비 절차와 관련 이미지를 동시에 제공하는 성능 개선을 보였다.

다만 본 연구는 실험 장비와 정비 교범이 특정 체계에 한정되어 있어, 다양한 무기체계와 이기종 교범 형식에 대한 일반화 가능성을 충분히 검증하지 못했다는 한계가 있다. 또한 평가 데이터 세트가 약 100건의 질의에 기반하고 있어, 실제 운용 환경에서 발생하는 예외적인 상황이나 복합 고장 시나리오에 대한 성능은 추가 검증이 필요하다. 시스템이 사용하는 LLM 역시 특정 크기(약20B)와 하드웨어 환경을 전제로 평가되었으므로, 더 경량이거나 다른 아키텍처의 모델에 대한 성능 및 비용,효율성 분석은 향후 연구 과제로 남는다. 아울러 본 연구에서는 실제 부대 운용 환경에서의 정비 시간 단축이나 인적 오류 감소를 직접 계측하지 않았으므로, 정비 효율성 향상에 대한 논의는 제안 시스템의 응답 정확도 개선을 기반으로 한 기대 효과로 한정된다.

본 연구는 방대한 양의 교범을 그대로 지식베이스로 사용하지 않고 데이터 분리 및 재구성을 통해 효율적인 지식베이스를 구축하고 경량화된 LLM과 에이전트 아키텍처를 결합하여, 제한된 하드웨어 환경(온프레미스)에서도 고성능의 정비지원이 가능한 효율적인 RAG 시스템 구성 방안을 제시했다는 점에서 중요한 의의가 있다. 본 시스템은 정비사의 정보 접근성을 향상시키고 정비 시간을 단축하며, 궁극적으로 인적 오류 감소와 무기체계 가동률 향상에 이바지할 수 있을 것으로 기대된다. 향후 연구로는 다양한 장비 및 교범 유형으로의 확장 실험, 텍스트가 포함된 이미지 혹은 이미지 형태의 텍스트에 대한 검색 및 인지 기능 고도화, 실제 부대 운용 환경에서의 장기 필드 테스트를 통한 운영상 한계 및 개선점 도출 등을 수행하고자 한다.

참고문헌(Reference)

- [1] J.-M. Rhee, D.-J. Jeon, Y.-G. Kim, and S. Kim, "The Operational Availability Improvement based on PMS & CBM+ Strategy," Journal of the Korea Academia-

- Industrial Cooperation Society, Vol.25, No.6, pp.246-252, 2024. <https://doi.org/10.5762/KAIS.2024.25.6.246>
- [2] S.-J. Park and E.-C. Jeon, "A Study on the Safety and Management Plan of Aviation Maintenance due to Human Error," Journal of the Korean Society of Manufacturing Process Engineers, Vol.19, No.10, pp.68-73, 2020. <https://doi.org/10.14775/ksmpe.2020.19.10.068>
- [3] C. Wang, J. Zhao, and J. Gong, "A Survey on Large Language Models from Concept to Implementation," arXiv preprint, arXiv:2403.18969, 2024. <https://arxiv.org/abs/2403.18969>
- [4] Z. Xu, S. Jain, and M. Kankanhalli, "Hallucination is Inevitable: An Innate Limitation of Large Language Models," arXiv preprint, arXiv:2401.11817, 2024. <https://arxiv.org/abs/2401.11817>
- [5] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," arXiv preprint, arXiv:2311.05232, 2023. <https://arxiv.org/abs/2311.05232>
- [6] K.-S. Moon, M.-J. Kang, H.-Y. Yoo, and Y.-T. Shin, "Research on the Application of Large Language Models (LLMs) in the Defense Domain," Journal of the Korea Academia-Industrial Cooperation Society, Vol.25, No.8, pp.484-492, 2024. <https://doi.org/10.5762/KAIS.2024.25.8.484>
- [7] S.-U. Lee, S.-H. Lee, H.-C. Yu, S.-S. Park, and W.-H. Kim, "Analyzing and Addressing Challenges of LLM Applications in Defense," Journal of Defense and Security, Vol.6, No.1, pp.302-328, 2024. <https://www.kci.go.kr/kciportal/ci/sereArticleSearch/ciSereArtiView.kci?sereArticleSearchBean.artiId=ART003094955>
- [8] Google AI, Introducing Gemini: Our Largest and Most Capable AI Model, Google AI Blog, 2023. <https://blog.google/technology/ai/google-gemini-ai/>
- [9] S. M. T. I. Tonmoy et al., "A Comprehensive Survey of Hallucination Mitigation Techniques in Large Language Models," arXiv preprint, arXiv:2401.01313, 2024. <https://arxiv.org/abs/2401.01313>
- [10] D. Quinn et al., "Accelerating Retrieval-Augmented Generation," in Proc. of the 30th ACM International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '25), Vol.1, pp.15-32, 2025. <https://dl.acm.org/doi/10.1145/3669940.3707264>
- [11] W. Kim et al., "Accelerating Inference in Retrieval-Augmented Generation Models for Long-Form Question Answering via Dynamic Token Pruning," Mathematics, Vol.13, No.14, 2025. <https://doi.org/10.3390/math13142231>
- [12] Z. Li et al., "Retrieval Augmented Generation or Long-Context LLMs? A Comprehensive Study and Hybrid Approach," in Proc. of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track, pp.881-893, 2024. <https://aclanthology.org/2024.emnlp-industry.66>
- [13] Z. Jiang et al., "Active Retrieval Augmented Generation," in Proc. of the 2023 Conference on Empirical Methods in Natural Language Processing, pp.7969-7992, 2023. <https://doi.org/10.18653/v1/2023.emnlp-main.495>
- [14] Y. Chen et al., "Benchmarking Large Language Models in Retrieval-Augmented Generation," in Proc. of the AAAI Conference on Artificial Intelligence, Vol.38, No.16, pp.17754-17762, 2024. <https://ojs.aaai.org/index.php/AAAI/article/view/29728>
- [15] W. Jiang et al., "Artificial Intelligence Agent-Enabled Predictive Maintenance: Conceptual Proposal and Basic Framework," Computers, Vol.14, No.8, 2025. <https://doi.org/10.3390/computers14080329>
- [16] Artificial Intelligence Times, Mind AI successfully completed the 'Army Headquarters Intelligent Smart Unit Pilot Construction Project'..."Application of search augmentation generation to speed up decision-making and simplify administrative work", 2025. <https://www.aitimes.kr/news/articleView.html?idxno=33589>
- [17] P. Lewis, E. Perez, A. Piktus, et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in Proc. of NeurIPS (Neural Information Processing Systems), No.793, pp.9459-9474, 2020. <https://doi.org/10.48550/arXiv.2005.11401>
- [18] F. Petroni, T. Rocktäschel, S. Riedel, P. Lewis, A. Bakhtin, Y. Wu, and T. Miller, "Language Models as Knowledge Bases?," in Proc. of the 2019 Conference on Empirical Methods in Natural Language Processing

and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pp.2463-2473, 2019.
<https://doi.org/10.18653/v1/D19-1250>

[19] R. Zhao, H. Chen, W. Wang, F. Jiao, X. L. Do, C. Qin, B. Ding, X. Guo, M. Li, X. Li, and S. Joty, "Retrieving Multimodal Information for Augmented Generation: A Survey," arXiv preprint arXiv:2303.10868, 2023.
<https://arxiv.org/abs/2303.10868>

❶ 저 자 소 개 ❶



김 건 희(Geon-Hee Kim)

2023년 경운대학교 항공소프트웨어공학과(공학사)
2023년~현재 LIG시스템 AI기술연구소 연구원
관심분야 : 생성형 AI, 딥러닝, 머신러닝, 데이터분석
E-mail : gunhee.kim@lig.kr



추 건 호(Keon-Ho Chu)

2021년 건국대학교 의항공학과(공학사)
2023년 질병관리청 MLE
2024년 Bionutrition AI 엔지니어
2025년~현재 LIG시스템 AI기술연구소 연구원
관심분야 : 생성형 AI, Graph RAG, Ontology
E-mail : keonho.chu@lig.kr



노 웅 석(Woong-Seok Roh)

2002년 서강대학교 컴퓨터공학과(공학사)
2020년 고려대학교 빅데이터융합학과(공학석사)
2002년~현재 LIG D&A IPS 연구소
관심분야 : Machine Learning, IPS, LLM
E-mail : woongseok@ligdna.com



최 종 천(Jong-Cheon Choi)

2005년 단국대학교 대학원 컴퓨터학과(이학석사)
2014년 단국대학교 대학원 컴퓨터학과(이학박사)
2020년~현재 LIG시스템 AI기술연구소
관심분야 : 인공지능, MSA, 시스템보안, 사이버전장체계
E-mail : jongcheon.choi@lig.kr